

COSIE 中切片内跨模态对比学习方法总结（源码严谨版）

1. 核心结论

COSIE 的切片内跨模态对比学习不是 SimCLR / CLIP / InfoNCE 式的样本级正负样本对比，而是一个 dimension-level、mutual-information-style 的 cross-view contrastive objective。

更准确地说，COSIE 在同一个 section 内，对共同观测到的不同模态 latent embeddings 构造一个归一化后的 dimension-level dependency matrix，并基于这个矩阵计算一个 negative mutual-information-like loss，同时加入 entropy regularization，用来增强不同模态表示之间的统计依赖。

需要注意的是，这里最好说成：

“mutual-information-style objective”

或者：

“information-theoretic-style contrastive objective”

而不要过于绝对地说成：

“严格的 mutual information estimator”

因为从源码实现看，COSIE 的 crossview_contrastive_Loss 确实借鉴了互信息最大化和熵正则的形式，但它并不是一个严格概率模型下的标准 mutual information estimator。

2. 使用位置

COSIE 的 cross-view contrastive loss 使用在同一个 tissue section 内的共同观测模态之间。

整体流程可以写成：

原始模态特征 -> modality-specific graph autoencoder -> 得到每个模态的 latent embedding -> 对同一 section 内 co-observed modalities 的 latent embeddings 计算 cross-view contrastive loss

也就是说，COSIE 的切片内对比学习不是直接作用在原始 RNA count、原始 protein intensity 或 H&E image pixels 上，而是作用在各模态经过 graph autoencoder 编码后的 latent embeddings 上。

假设第 s 个 section 中同时观测到两个模态 $m1$ 和 $m2$ 。经过各自的 modality-specific graph autoencoder 后，得到：

$Z_{s_m1} \in \mathbb{R}^{(N_s \times K)}$

$Z_{s_m2} \in \mathbb{R}^{(N_s \times K)}$

其中：

N_s 表示第 s 个 section 中的 spot / cell / superpixel 数量。

K 表示 latent embedding 维度。

$Z_{s_m1}[i, :]$ 表示第 i 个空间位置在模态 $m1$ 下的 latent embedding。

$Z_{s_m2}[i, :]$ 表示第 i 个空间位置在模态 $m2$ 下的 latent embedding。

COSIE 的切片内 cross-view contrastive loss 就是在 Z_{s_m1} 和 Z_{s_m2} 之间计算。

3. 它对齐的是什么

COSIE 的切片内 contrastive loss 对齐的是同一个 section 内不同模态 latent embeddings 的统计结构，而不是直接对齐原始特征。

例如，一个 section 同时有 H&E 和 RNA。

H&E 经过 H&E foundation model 和 graph autoencoder 后得到：

Z_{s_img}

RNA 经过预处理和 graph autoencoder 后得到：

Z_{s_rna}

COSIE 希望这两个 latent embeddings 之间具有更强的统计依赖。

直观来说，如果 H&E embedding 中包含“肿瘤区域”“间质区域”“免疫浸润区域”“平滑肌区域”等形态信息，那么 RNA embedding 中也应该在一定程度上包含相应的分子表达状态。COSIE 的 cross-view contrastive loss 就是用来增强这种跨模态共享信息。

但是，它不是强制：

$Z_{s_img}[i, :] = Z_{s_rna}[i, :]$

也不是直接用 MSE 拉近同一个 spot 的两个模态 embedding。

它更接近于：

增强两个模态 latent dimensions 之间的统计依赖，使不同模态在同一 section 内形成更一致的表示结构。

4. 它不是标准 InfoNCE

标准的 SimCLR / CLIP / InfoNCE 对比学习通常是 sample-level contrastive learning。

如果用于 H&E-RNA，可以理解为：

positive pair = 同一个 spot 的 H&E embedding 和 RNA embedding

negative pair = 不同 spot 的 H&E embedding 和 RNA embedding

其常见形式类似：

$$L_i = -\log \exp(\text{sim}(z_{\text{img}_i}, z_{\text{rna}_i}) / \tau) / \sum_j \exp(\text{sim}(z_{\text{img}_i}, z_{\text{rna}_j}) / \tau)$$

这种方法会构造一个 $N_s \times N_s$ 的 spot-level similarity matrix。

但 COSIE 的 crossview_contrastive_Loss 不是这种形式。

COSIE 不显式构造：

same-spot positive pairs

different-spot negative pairs

也不显式计算：

$$\text{sim}(z_{\text{img}_i}, z_{\text{rna}_j})$$

这样的 $N_s \times N_s$ 样本相似度矩阵。

COSIE 构造的是 $K \times K$ 的 dimension-level joint-dependency matrix，也就是两个模态 latent dimensions 之间的统计依赖矩阵。

因此，更准确的说法是：

COSIE 的切片内跨模态对比学习不是 InfoNCE / CLIP-style sample-level contrastive learning，而是 dimension-level mutual-information-style cross-view contrastive learning。

5. 源码更一致的 joint matrix 构造方式

假设第 s 个 section 内有两个模态 $m1$ 和 $m2$ ：

$$Z_{s_m1} \in \mathbb{R}^{(N_s \times K)}$$

$$Z_{s_m2} \in \mathbb{R}^{(N_s \times K)}$$

源码逻辑更接近下面这种形式：

$$P_{\text{raw}}[a,b] = \sum_i Z_{s_m1}[i,a] * Z_{s_m2}[i,b]$$

然后对 P_{raw} 做对称化：

$$P = (P_{\text{raw}} + P_{\text{raw}}^T) / 2$$

再做整体归一化：

$$P = P / \text{sum}(P)$$

因此，相比写成：

$$P_{ab} = (1 / N_s) * \sum_i Z_{s_m1}[i,a] * Z_{s_m2}[i,b]$$

更贴近源码的写法是：

$$P_{\text{raw}}[a,b] = \sum_i Z_{s_m1}[i,a] * Z_{s_m2}[i,b]$$

$$P = (P_{\text{raw}} + P_{\text{raw}}^T) / 2$$

$$P = P / \text{sum}(P)$$

这里的 P_{ab} 表示模态 m1 第 a 个 latent dimension 和模态 m2 第 b 个 latent dimension 之间的归一化共变关系或依赖关系。

需要注意：

虽然论文和代码中会把 P 当作 joint probability matrix 使用，但从严格数学角度看， P 不一定是标准意义上的联合概率分布。因为 GAE 输出通常经过 L2 normalize，而不是 softmax，latent 值理论上可能为负。源码中对小于 EPS 的值进行了截断处理，但这并不等价于严格概率建模。

因此更严谨的表述是：

P is a normalized joint-probability-like dependency matrix between latent dimensions.

中文可以说：

P 是两个模态 latent dimensions 之间的归一化 joint-probability-like 依赖矩阵。

或者：

P 是源码中作为 joint probability matrix 使用的归一化 dimension-level dependency matrix，但由于 latent embedding 不保证非负，它并不是严格概率论意义上的联合分布。

6. marginal dependency 的计算

得到 P 后，COSIE 进一步计算两个边缘项：

$$P_a = \sum_b P_{ab}$$

$$P_b = \sum_a P_{ab}$$

其中：

P_a 表示模态 $m1$ 第 a 个 latent dimension 的边缘依赖强度。

P_b 表示模态 $m2$ 第 b 个 latent dimension 的边缘依赖强度。

如果把 P 近似看成 joint-probability-like matrix，那么 P_a 和 P_b 就对应两个模态 latent dimensions 的 marginal distributions。

但为了严谨，可以把它们称为：

marginal dependency terms

或者：

marginal probability-like terms

而不是过于绝对地称为严格概率分布。

7. COSIE 的 cross-view contrastive loss

对于 section s 内的一对模态 $m1$ 和 $m2$ ，COSIE 的 cross-view contrastive loss 可以写成：

$$L_{con}^{(s,m1,m2)} = - \sum_a \sum_b P_{ab} * \log(P_{ab} / (P_a^{(\gamma+1)} * P_b^{(\gamma+1)}))$$

其中：

P_{ab} 是两个模态 latent dimensions 之间的 joint-probability-like dependency matrix 中的元素。

P_a 是对 P 的行求和得到的 marginal term。

P_b 是对 P 的列求和得到的 marginal term。

γ 是 entropy regularization coefficient。

K 是 latent embedding 维度。

这个 loss 的形式类似 mutual information maximization with entropy regularization。

从优化方向上看，最小化 L_{con} 可以解释为增强两个模态 latent embeddings 之间的统计依赖，同时通过 entropy-related terms 避免维度使用塌缩。

8. 为什么说它是 mutual-information-style objective

标准互信息可以写成：

$$I(X,Y) = \sum_a \sum_b P_{ab} * \log(P_{ab} / (P_a * P_b))$$

COSIE 的 loss 形式为：

$$L_{con} = - \sum_a \sum_b P_{ab} * \log(P_{ab} / (P_a^{(\gamma+1)} * P_b^{(\gamma+1)}))$$

它与标准互信息公式非常接近，但分母中不是简单的 $P_a * P_b$ ，而是：

$$P_a^{(\gamma+1)} * P_b^{(\gamma+1)}$$

这相当于在互信息式目标之外引入了与边缘熵相关的正则项。

因此，它可以被解释为：

negative mutual-information-like loss with entropy regularization

或者：

mutual-information-style cross-view contrastive objective

但最好不要把它表述成严格的互信息估计器。

更稳妥的中文表述是：

COSIE 的 cross-view contrastive loss 具有互信息最大化的形式，可以从信息论角度解释为增强两个模态 latent representations 之间的统计依赖，并通过熵相关项缓解表示坍缩。

9. entropy regularization 的作用

COSIE 的 loss 中引入 γ 相关项，可以理解作为一种 entropy regularization。

它的主要作用是：

鼓励 latent dimensions 被更充分地使用。

减少所有信息集中到少数几个维度的风险。

缓解 representation collapse 或维度坍缩。

让 cross-view dependency 不至于通过退化表示获得。

需要注意的是，entropy regularization 主要是帮助避免维度使用坍缩，不能单独说它负责保留所有 modality-specific information。

COSIE 中 modality-specific information 的保留主要来自三方面：

第一，每个模态有自己的 modality-specific graph autoencoder。

第二，每个模态有 reconstruction loss，用来保证 embedding 保留原始模态信息。

第三，COSIE 的 contrastive loss 没有强制不同模态 embedding 完全相同，而只是增强它们的统计依赖。

因此更严谨的说法是：

entropy regularization 有助于避免维度使用塌缩；modality-specific information 主要由 modality-specific encoders 和 graph autoencoder reconstruction loss 保留。

10. 对所有 section 和 co-observed modality pairs 求和

如果一个 section 中有多个共同观测到的模态，COSIE 可以对这些模态对分别计算 cross-view contrastive loss。

总的 contrastive loss 可以写成：

$$L_{con} = \sum_{s \in S} \sum_{(m1, m2) \in P_s} L_{con}^s(s, m1, m2)$$

其中：

S 表示所有 tissue sections。

P_s 表示第 s 个 section 内所有共同观测到、参与 cross-view contrastive learning 的模态对集合。

$L_{con}^s(s, m1, m2)$ 表示 section s 中模态 $m1$ 和模态 $m2$ 之间的 cross-view contrastive loss。

例如：

如果 section 1 有 H&E 和 RNA，可以计算 H&E-RNA contrastive loss。

如果 section 2 有 RNA 和 protein，可以计算 RNA-protein contrastive loss。

如果某个 section 有 H&E、RNA、protein 三个模态，则可以对其中的 co-observed modality pairs 计算 cross-view contrastive loss。

对于 metabolomics，需要更谨慎表述：

如果 Metabolite 作为一个普通 modality 被预处理并放入 feature_dict，COSIE-style 框架原则上可以按同样方式对其进行 graph encoding 和 cross-view contrastive learning。但 COSIE 源码没有专门的 metabolomics-specific contrastive learning 逻辑。也就是说，Metabolite 是作为普通 modality 被框架处理，而不是有一套单独为代谢组设计的对比学习模块。

11. 总 loss 的源码严谨写法

需要注意，COSIE 源码中的 loss 权重和一种常见表述略有不同。

更贴近源码的总 loss 是：

$$L_{\text{total}} = L_{\text{con}} + \lambda_1 L_{\text{rec}} + \lambda_2 L_{\text{pred}} + \lambda_3 L_{\text{tri}}$$

其中：

L_{con} 是 $\text{total_contrastive_loss}$ 。

L_{rec} 是 $\text{total_reconstruction_loss}$ 。

L_{pred} 是 $\text{total_prediction_loss}$ 。

L_{tri} 是 $\text{total_triplet_loss}$ 。

λ_1 是 reconstruction loss 的权重。

λ_2 是 prediction loss 的权重。

λ_3 是 triplet loss 的权重。

这和下面这种写法不同：

$$L_{\text{total}} = L_{\text{rec}} + \lambda_1 L_{\text{con}} + \lambda_2 L_{\text{pred}} + \lambda_3 L_{\text{tri}}$$

上面这种写法会把 λ_1 误认为 contrastive loss 的权重，而源码中 λ_1 实际上是 reconstruction loss 的权重。

因此，如果要贴近源码，应该写：

$$\text{loss} = \text{total_contrastive_loss} + \lambda_1 * \text{total_reconstruction_loss} + \lambda_2 * \text{total_prediction_loss} + \lambda_3 * \text{total_triplet_loss}$$

默认情况下， $\lambda_1 = 0.1$ 表示 reconstruction loss 的权重，而不是 contrastive loss 的权重。

12. 与 bidirectional prediction 的区别

COSIE 的切片内 cross-view contrastive loss 和 bidirectional prediction loss 是两套机制。

cross-view contrastive loss 主要做的是：

增强同一个 section 内不同模态 latent embeddings 之间的统计依赖。

它不显式构造同 spot positive pairs 和 different spot negative pairs。

也不直接用 MSE 强制同一 spot 的两个模态 embedding 接近。

而 bidirectional prediction loss 更直接体现了同 spot / same-location 的跨模态对应关系。

例如：

Z_s_img -> Img2RNA predictor -> predicted Z_s_rna

Z_s_rna -> RNA2Img predictor -> predicted Z_s_img

然后用 predicted embedding 和真实 target embedding 之间的 MSE 进行约束。

所以更严谨地说：

同一 spot 行级别的跨模态对齐，更直接地体现在 bidirectional prediction MSE 中。

cross-view contrastive loss 则主要通过 dimension-level dependency matrix 增强两个模态整体表示之间的统计依赖。

13. 与 triplet loss 的区别

COSIE 的切片内 contrastive loss 和跨切片 triplet loss 也不能混淆。

切片内 contrastive loss：

作用范围是同一个 section 内。

对象是 co-observed modalities 的 latent embeddings。

目标是增强不同模态表示之间的统计依赖。

不显式构造 spot-level positives / negatives。

跨切片 triplet loss：

作用范围是不同 sections 之间。

对象是通过 cross-section linkage 找到的 anchor-positive pairs 和 negative samples。

目标是让不同切片中相似的组织区域靠近，让不相关区域远离。

显式使用 anchor、positive、negative。

因此，COSIE 中显式 negative samples 主要出现在 cross-section triplet loss 中，而不是切片内 cross-view contrastive loss 中。

可以概括为：

within-section contrastive learning 负责跨模态表示一致性。

cross-section triplet learning 负责跨切片 / 跨样本组织区域对齐。

14. 更准确的最终表述

COSIE 的切片内跨模态 contrastive loss 不是 InfoNCE / CLIP-style 的样本级正负样本对比，而是一个 dimension-level、mutual-information-style 的 cross-view objective。它在同一个 tissue section 内，对共同观测到的模态 latent embeddings 构造归一化的 joint-dependency matrix，并基于该矩阵及其 marginal terms 计算 negative mutual-information-like loss。这个 loss 通过 entropy regularization 缓解维度使用塌缩，从而增强不同模态表示之间的统计依赖。

需要强调的是，该 loss 不显式构造 spot-level positive 和 negative pairs；同 spot 行级别的跨模态对应更直接体现在 bidirectional prediction MSE 中，而显式 negative samples 主要出现在跨 section linkage 驱动的 triplet loss 中。modality-specific information 的保留主要依赖 modality-specific graph autoencoders、reconstruction loss，以及 COSIE 没有强制不同模态 embedding 完全相同这一设计。

15. 可用于论文/报告的方法描述版本

中文版本：

COSIE 在切片内多模态学习阶段使用了一种 dimension-level、mutual-information-style 的 cross-view contrastive loss，而不是标准的 InfoNCE / CLIP-style 样本级正负样本对比。具体来说，对于同一 tissue section 内共同观测到的两个模态，模型首先通过模态特异性图自编码器得到对应的 latent embeddings。随后，COSIE 根据两个模态 latent dimensions 之间的乘积关系构造一个归一化的 joint-dependency matrix，并由该矩阵计算 marginal terms。基于这些量，模型最小化一个 negative mutual-information-like objective，并通过 entropy regularization 缓解 latent dimension 使用塌缩。该目标增强了共同观测模态之间的统计依赖，使不同模态能够共享组织状态相关的生物学信息。与标准 InfoNCE 不同，该方法不显式构造同一 spot 的 positive pair 和不同 spot 的 negative pairs；同一空间位置的跨模态行级对应主要由后续的 bidirectional prediction loss 约束，而显式负样本主要用于跨切片 triplet learning。

英文版本：

COSIE employs a dimension-level, mutual-information-style cross-view contrastive loss during within-section multimodal learning, rather than a standard InfoNCE or CLIP-style sample-level contrastive objective. For two co-observed modalities within the same tissue section, modality-specific graph autoencoders first produce their latent embeddings. COSIE then constructs a normalized joint-dependency matrix based on the products between latent dimensions of the two modality embeddings and derives marginal terms from this matrix. A negative mutual-information-like objective with entropy regularization is minimized to enhance statistical dependency between co-observed modalities while mitigating latent dimension collapse. Unlike standard InfoNCE, this loss does not explicitly define same-spot positive pairs or different-spot negative pairs. Same-location cross-modal correspondence is more directly enforced by the bidirectional prediction loss, whereas explicit negative samples are mainly used in the cross-section triplet learning module.

16. 最简洁版总结

COSIE 的切片内跨模态对比学习可以简洁概括为：

COSIE 对同一 section 内共同观测到的模态 embeddings 使用一个 dimension-level、mutual-information-style 的 cross-view contrastive loss。该方法先构造两个模态 latent dimensions 之间的归一化 joint-dependency matrix，再通过 negative mutual-information-like objective 加 entropy regularization 来增强不同模态表示之间的统计依赖并缓解维度塌缩。它不是 InfoNCE / CLIP 式的样本级正负样本对比，不显式构造 same-spot positives 和 different-spot negatives；同 spot 跨模态对应主要由 bidirectional prediction MSE 约束，显式负样本主要用于跨切片 triplet loss。